

## **1 - Identificação do AnteProjeto de Pesquisa**

### **1.1. Título do AnteProjeto**

ANÁLISE DE MODELOS DE APRENDIZADO DE MÁQUINA PARA PREDIÇÃO DE FALHA MECÂNICA DE EQUIPAMENTOS FLORESTAIS

### **1.2. Participantes**

**Orientador: Denise Prado Kronbauer**

Currículo Lattes:

CPF: XXX.XXX.XXX-XX

**Pesquisador:**

Jean Carlos da Cruz

Currículo Lattes:

RA: XXXX

CPF: 735.252.861-04

### **1.3. Área ou Linha de Pesquisa**

Exemplo :XXXXXXXXXXXXXXXXXXXXX

[Será passado pela professora Anita]

### **1.4. Palavras Chaves**

Exemplo: manutenção preventiva, aprendizado de máquina, regressão

### **1.5. Área de Conhecimento do Projeto (CNPQ)**

1. Ciências Exatas e da Terra

1.03.00.00-7 Ciência da Computação

## Sumário

---

<b>2 - RESUMO</b>	<b>3</b>
<b>3 – CONTEXTUALIZAÇÃO E PROBLEMÁTICA</b>	<b>4</b>
<b>4 - JUSTIFICATIVA</b>	<b>5</b>
<b>5 – OBJETIVO DO TRABALHO</b>	<b>6</b>
<b>6 – METODOLOGIA</b>	<b>7</b>
<b>7 – RESULTADOS ESPERADOS</b>	<b>8</b>
<b>8 – EQUIPAMENTO E MATERIAL</b>	<b>9</b>
<b>9 – CRONOGRAMA</b>	<b>10</b>
<b>10 – BIBLIOGRAFIA</b>	<b>11</b>

## 2 - Resumo

A função Manutenção representa uma importante atividade em qualquer operação mecanizada, independente da posição hierárquica que ocupa na corporação. As máquinas não são eternas, e durante a sua vida útil precisam de um acompanhamento minucioso para que possam apresentar bom desempenho, com disponibilidade e confiabilidade favoráveis. Uma máquina, quando está em operação, custa caro. Parada, então, custa mais caro ainda, além de nada produzir (PACCOLA, J.E., 2017).

Nesse contexto, sem estratégias visando a redução das manutenções corretivas, ou seja, aquelas que acontecem quando o equipamento efetivamente falha, não é possível cumprir os cronogramas de produção, ter um portfólio de produtos de qualidade e controlar (e tentar minimizar) os custos de produção. Esses fatores interferem diretamente na competitividade da indústria no mercado e fidelidade dos clientes, que buscam produtos de qualidade e custo justo.

Portanto, não é uma surpresa que a Manutenção Preventiva tenha emergido rapidamente como um dos principais casos de uso da Indústria 4.0. Sua implementação possibilita monitorar a integridade dos ativos, otimizar os cronogramas de manutenção e obter alertas em tempo real dos riscos operacionais, benefícios estes que se encontram com as necessidades atuais das organizações (EZRA, 2018).

Dentre as técnicas utilizadas visando o aumento da manutenção preventiva, podemos citar as técnicas de *Machine learning* (em português Aprendizagem de Máquina) é um método de auto aprendizado computadorizado que reside no centro da maioria dos aplicativos de Inteligência Artificial. Os modelos de ML combinam habilidades avançadas de aprendizado de padrões, com a capacidade de se adaptar à medida que as mudanças ocorrem nos dados de entrada (EZRA, 2018).

Ou seja, seus algoritmos aprendem a partir dos dados a eles submetidos e, assim, as máquinas são treinadas para aprender a executar diferentes tarefas de forma autônoma. Logo, ao serem expostas a novos dados, elas se adaptam, a

partir dos cálculos anteriores, e os padrões se moldam para oferecer respostas confiáveis (RICHTER, 2019).

Sendo assim, esse projeto tem por objetivo analisar modelos de aprendizado de máquina aplicados a base de dados histórica de manutenção de empresas florestais com o objetivo de prever potencial momento de falha dos equipamentos, assim potencialmente aumentando a precisão das manutenções preventivas realizadas nos equipamentos.

### **3 – Contextualização e Problemática**

Com a intensificação de uma economia globalizada, houve também um crescimento na demanda por equipamentos e sistemas com melhor desempenho aliado ao baixo custo. Também surgiu a necessidade de redução na probabilidade de ocorrência de falhas nos produtos, considerando que essas falhas podem levar a um aumento dos custos dos produtos ou até acidentes. Com a análise e minimização dos diversos tipos de falhas, busca-se o aumento da confiabilidade dos equipamentos (FOGLIATTO e RIBEIRO, 2009).

De acordo com Anzanello et al. (2003), a confiabilidade pode ser definida como a probabilidade de um sistema operar de maneira satisfatória (sem falhas) em um período de tempo conhecido e condições definidas no projeto. Em algumas situações, a confiabilidade deve ter um nível extremamente alto, pela consequência que a falha pode ocasionar. As ocorrências de falhas são toleradas em algumas situações, mas podem gerar danos à imagem de uma empresa.

Assim, a falha pode ser definida como uma inoperância de um produto, que não executa a função para a qual foi projetado (WUTTKE e SELLITO, 2008). Uma falha pode gerar uma situação indesejada como uma simples parada de máquina, prejuízos financeiros, e até algo pior como o risco de vidas humanas. Logo, não devem ser poupados esforços para minimizar e evitar os riscos de uma falha (LAFRAIA, 2001).

Nesse contexto, novas técnicas foram desenvolvidas no setor de manutenção, dentre elas a manutenção preditiva, que tem como objetivo minimizar ou evitar a queda no desempenho, seguindo um plano previamente elaborado, baseada nos intervalos definidos de tempos em tempos, sempre visando prolongar a vida útil das máquinas e equipamentos. Garantindo assim o aumento da eficiência e da produtividade (KARDEC; NASCIF, 2009).

Sendo assim, visando aumentar a precisão das manutenções preventivas, a aplicação de técnicas de aprendizado de máquina. Podendo essas, serem descritas como técnicas que utilizam algoritmos capazes de aprender de acordo com as respostas esperadas por meio associações de diferentes dados, os quais

podem ser números, imagens e tudo que possa ser identificado por essa tecnologia. Ao invés de executar as rotinas de software na mão, é aplicado um set específico de instruções para completar uma tarefa em particular, a máquina é “treinada” usando uma quantidade grande de dados e algoritmos que dão e ela a habilidade de aprender como executar a tarefa (MITCHELL, 1997).

#### **4 - Justificativa**

O presente projeto se justifica no sentido em que pela busca da excelência operacional, através da redução dos custos operacionais sem redução de qualidade é de vital importância para a sobrevivência de qualquer empresa florestal que utiliza equipamentos móveis em sua operação. Portanto a aplicação de técnicas de aprendizado de máquina a esse cenário de manutenção traz inovação a esse setor, uma vez que atualmente grande parte das empresas faz uso de métodos empíricos de manutenção preventiva ou mesmo concentram seus esforços em manutenções corretivas (o modelo mais custoso entre todos). Portanto, o tema possui relevância econômica dentro do mercado de commodities através do seu potencial de expansão para outros setores produtivos dessa cadeia. O tema é de total interesse do autor, uma vez que possui carreira desenvolvida com Analytics voltado para o mercado florestal e a potencial utilização das técnicas propostas no projeto pode contribuir ainda mais para o sucesso do mercado florestal no estado do Mato Grosso.

## 5 – Objetivo do Trabalho

### *Objetivo Geral:*

Analisar modelos de aprendizado de máquina para predição do potencial momento de falha dos equipamentos.

### *Objetivos Específicos:*

- Realizar a Análise Exploratória e Explanatória da base de dados;
- Analisar modelos distintos de aprendizado de máquina.



## 6 – Metodologia

O levantamento bibliográfico será inicialmente realizado através de livros, artigos científicos e referências sugeridas pelo orientador, focando assuntos que forneçam uma base de conhecimento para uma noção de como desenvolver o trabalho proposto. A biblioteca da FATEC SENAI, em conjunto com a Internet, serão os meios de pesquisa a serem utilizados.

A coleta dos dados necessários para análise exploratória e explanatória se dará pela disponibilização da base histórica de manutenções mecânicas realizadas durante os anos de 2020 e 2021 por uma empresa localizada no estado de Mato Grosso. Os dados serão cedidos em formato de tabela estruturada (.xlsx). A análise dos dados se dará utilizando a linguagem python através do software livre Jupyter Lab. De posse dos dados, a primeira etapa será a *Data Wrangling*, que consiste na limpeza, estruturação e enriquecimento dos dados brutos, uma vez que geralmente tais dados são disponibilizados de forma não estruturada, não pronta para análise. A metodologia de EDA (do inglês *Exploratory Data Analysis*) seguirá o conceito “*top-down*” onde os dados serão analisados de forma agregada, através de estatística descritiva e criação de gráficos de distribuição de variáveis. Com base nos resultados da etapa de EDA, serão fornecidos resultados e insights das análises, consistindo essa como análise explanatória dos dados.

Após as etapas de análise exploratória e explanatória, se dará a etapa de análise de modelos distintos de aprendizado de máquina, inicialmente a base de dados será dividida em base de treinamento (75% do total, selecionado de forma aleatória) e base de teste (Restante 25% da base inicial). Os modelos a serem inicialmente testados serão:

- Regressão Linear Simples;
- Regressão Polinomial;
- Regressão Linear Múltipla;
- Árvore de Decisão;
- Random Forest;
- Gradient Boosting;
- Support Vector Regression;

Inicialmente os modelos serão analisados considerando todas as variáveis disponíveis, onde, com base nos resultados iniciais de cada modelo será realizada a análise de importância de cada variável analisada, com o objetivo de verificar a potencial exclusão de variáveis de baixa importância, objetivando melhorar o ajuste de cada modelo. As métricas de comparação entre os modelos serão:

- Raiz Quadrada do Erro Quadrático Médio (RMSE);
- Coeficiente de determinação ( $r^2$  quadrado);

Um modelo será considerado satisfatório quando seu  $r^2$  quadrado for superior a 0.75 quando aplicado à base de teste. Essa definição até o momento é totalmente empírica, podendo ser ajustada ao longo do projeto. Caso mais de um modelo obtenha  $r^2$  quadrado superior a 0.75, o modelo que será considerado o melhor entre os analisados será o que obtiver o maior  $r^2$  quadrado.

## **7 – Resultados Esperados**

Utilização de aprendizado de máquina para predição de falhas mecânicas em escala de produção, visando o aumento das manutenções preventivas e consequente redução de custos de manutenção em empresas florestais do estado de Mato Grosso.

## 8 – Equipamento e Material

No desenvolvimento do projeto serão utilizados um computador com as seguintes características:

*Processador i7-8700 CPU @ 3.20GHz 3.19 GHz;*

*Memória RAM 16GB;*

*Sistema Operacional Windows 10*

Os softwares e bibliotecas a serem utilizados serão:

*Google Sheets*

*Google Docs*

*Sublime Text*

*Jupyter Lab*

*Python 3.7*

*pandas*

*matplotlib*

*seaborn*

*scikit-learn*

*numpy*

## 9 – Cronograma

Atividades	ago./21	set./21	out./21	nov./21	dez./21	jan./21	fev./21	mar./21
Elaboração do Ante-projeto de Pesquisa (disciplina de Metodologia)								
Definição do Orientador								
Definição da metodologia final a ser utilizada na seleção e análise dos modelos								
Realizar a Análise Exploratória e Explanatória da base de dados;								
Analisar modelos distintos de aprendizado de máquina.								
Apresentação dos resultados ao orientador								
Revisão dos objetivos com base no feedback do orientador								
Escrita do Artigo								
Revisão no texto do artigo								
Entrega da versão final do artigo								

## 10 – Bibliografia

ANZANELLO, M. J.; SILVA, P. R. S.; RIBEIRO, J. L. D.; FOGLIATTO, F. S. **Proposição de modelo de degradação para capacitores submetidos a ensaios acelerados**. In: XXIII Encontro Nacional de Engenharia de Produção. Ouro Preto. ABEPRO, 2003.;

EZRA, Oren. **Achieving Manufacturing Excellence with Predictive Maintenance and Machine Learning**. In: Industry 4.0 Insights, 2018;

FOGLIATTO, F. S.; RIBEIRO, J. L. D. **Confiabilidade e manutenção industrial**. Rio de Janeiro: Elsevier, 2009. 265p.;

LAFRAIA, J. R. B. **Manual de confiabilidade, manutenibilidade e disponibilidade**. 2a Edição. Rio de Janeiro: Qualitymark, 2001.;

KARDEC, Alan; NASCIF, Júlio de Aquino. **Manutenção – Função estratégica**. Rio de Janeiro: Qualitymark, 2009.;

MITCHELL, T. M. **Machine Learning**. - New York: McGraw-Hill, 1997;

PACCOLA, J.E. **Manutenção e Operação de Equipamentos Móveis**. São José dos Campos, 2017.

RICHTER, Ian. **Achieving Zero Unplanned Downtime with Predictive Maintenance Analytics**. In: Industry 4.0 Insights, 2019.

WUTTKE, R. A.; SELLITO, M. A. **Cálculo da disponibilidade e da posição na curva da banheira de uma válvula de processo petroquímico**. Revista Produção Online, v. 8, n.4, p. 1-23, 2008.